

Agentic AI 2026

狂欢退潮之后，我们期望人人可用的 Inclusive AGI

王旭，蚂蚁开源技术委员会副主席

2026.05 | Ant Open Source & InclusionAI

00

写在前面

当黑客松快要结束，软件生产模式本身在移动

当黑客松式的狂欢冷却下来

过去

Human → UI → Software

人使用界面操作软件



2026

Agent → CLI / MCP / Tool → Software

Agent 读写文件、调用 API、发 PR、跑测试

那些热闹、速度、偶然、天才时刻冷却之后。我们真正要问：

软件会走向哪里？

开发者会变成什么？

开源还剩下什么位置？

为什么仍需要 inclusive AGI？


01

平台传来的生态信号

模型没有让软件变少，反而让软件的边界变宽了

GitHub/HuggingFace 平台增长信号

The number
of new
developers on
GitHub



GitHub 开发者总人数

1.8 亿


2025 年新增人数

3,600 万

平均每秒新增人数

1

HUGGING FACE'S TWO MILLION MODELS AND COUNTING



Source: HuggingFace & AI World

Hugging Face 公开模型数量

200 万

较过去一年数量增长

100%+

GitHub 协作榜 vs Star 增长榜： AI 挤进核心工程世界

Rank	GitHub Repos with Highest Collaboration	GitHub Repos Gained Most Stars
1	llvm/llvm-project	openclaw/openclaw
2	NixOS/nixpkgs	affaan-m/everything-claude-code
3	openclaw/openclaw	obra/superpowers
4	anthropics/claude-code	anomalyco/opencode
5	odoo/odoo	ultraworkers/claw-code
6	microsoft/vscode	anthropics/skills
7	pytorch/pytorch	NousResearch/hermes-agent
8	elastic/kibana	nextlevelbuilder/ui-ux-pro-max-skill
9	Expensify/App	msitarzewski/agency-agents
10	zephyrproject-rtos/zephyr	forrestchang/andrej-karpathy-skills

开发者的情绪和好奇心围绕着：


Agent


Claude Code


Skills


Workflow

而真实协作仍然围绕软件世界的

长期工程底座 和 **复杂系统**
展开。

02

AI 生态架构

通往 Agentic AI 的一整套执行栈

生态结构变化：从 LLM 工具链到 Agent 执行栈

2025 年：Landscape 还在梳理 SDK、RAG、ChatUI 和 MLOps；

2026 年：头部项目已经围绕 Agent 的任务执行系统重排。

2025.05

LLM 工具链

Agent 还没有进入真实任务

- Agent 生态仍是开发框架生态；
- RAG 和 Vector Search 独立成类；
- Coding 仅是 IDE 里的代码补全和问答；

2025.09

Agent 化开始

从「怎么写 Agent」转向「能不能进入任务执行」

- AI Coding、Agent Tool 独立分化；
- MCP 协议层广泛应用，工具开始互相打通；
- 推理服务层多极并进，持续竞争；

2026.05

Agent 执行栈

执行边界向真实世界伸手

- Browser Agent 是第一站：
网页是数字世界的 GUI
- Sandbox 是第二站：
代码执行需隔离
- Embodied 是更远的一站：
现实世界比软件环境难得多

Agentic AI 三层生态架构



从上层任务入口，到中层 token 供应链，再到底层模型能力；Agent 时代的软件栈正在重新分工。



Agent Infra 决定 AI 能替谁做事

Model Infra 决定这件事能不能规模化

Model 决定能力边界在哪里


...至少目前看是这样

从静态全景图，到动态排行榜

[Model](#)[System](#)[Research](#)[Insights](#)[Blog](#)[About](#)

Data-driven community insights to what matters in the AI open-source development space produced by InclusionAI.

Landscapes



Agentic AI Leaderboard

powered by [OpenDigger](#)

头部活跃度：Agent 和基础设施并列成为生态中心

排名	项目	协作活跃度 (OpenRank)	参与人数	趋势	介绍
1	 OPENCLAW	1,368.43	2,980		个人 Agent / coding / workflow 的超级入口
2	 LLM	1078.67	1,283		LLM 推理服务
3	 PyTorch	1041.30	620		深度学习基础设施
4	 Claude Code	810.36	4,015		Coding Agent 代表性产品
5	 SGL	497.96	530		高性能推理 / structured generation
6	 CODEX	474.90	1,069		Coding Agent 代表性产品
7	 HERMES-AGENT	473.32	1,651		Personal / autonomous agent
8	 opencode	471.04	1,124		开源兼容的 coding agent
9	 LangChain	359.67	429		Agent 开发框架
10	 GEMINI	355.52	474		Coding Agent 代表性产品

Agent Infra Landscape 2026

Agentic Coding

Personal AI Assistant

Coding Agent

Claude Code

CODEX

opencode

GEMINI

F1 Pi

Kilo

codename goose

Qwen Code

warp

Cline

GitHub Copilot

OpenHands

Kimi Code CLI

OpenClaude

Continue

Crush

Coding Harness

Superpowers

Everything ClaudeCode

Oh My OpenAgent

oh-my-claudecode

oh-my-codex

OPENCLAW

HERMES-AGENT

QwenPaw

NanoClaw

ZeroClaw

AstrBot

Chatbot

Cherry Studio

Open WebUI

LibreChat

Agent Framework

Multi-agent Orchestration

DeerFlow

Paperclip

Mastra

LobeHub

Aden Hive

Multica

Workflow Platform & Agent Builder

n8n

Dify

activepieces

Langflow

Comfy

Code-First Agent Framework

Vercel

deepagents

Pydantic AI

agno

LiveKit Agents

Pipecat

adk-python

langchain

CopilotKit

langgraph

crewai

OpenFang

OpenAI Agents SDK

Agent Runtime Infra

Memory, Knowledge & Context

RAGFlow

Beads

claude-mem

MemPalace

Hindsight

mem0

supabase

seekdb

memu

Protocols & Tool Interoperability

Model Context Protocol

Skills

A2A

Tool Use

Agent Browser

Browser Use

page-agent.js

Browser Harness

Observability & Evaluation

opik

langfuse

Arize Phoenix

promptfoo

Model API Proxy

LiteLLM

CLIProxyAPI

Higress

cc-switch

New API

rtk

Dev Environment & Sandbox


CODER

OpenSandbox

Daytona

Agent Infra: 重新定义软件如何被使用

软件正在被重新包装为 Agent 可进入的运行环境，而运行时需要的 Agent Runtime 部件正在变成 Agent Infra 的骨架。



入口变化

UI 不再是唯一入口，API、MCP、工具协议成为新入口

上下文变化

软件要暴露状态、历史、权限、环境和可读文档

执行变化

Agent 读文件、跑命令、改代码、发 PR，进入 workflow

EVIDENCE STRIP · 生态注意力已经扩散到 Agent Runtime 部件

多标签分类，有重叠；横向看结构，不做加总。

Coding Agent

78 projects
participants · 14,019

MCP

59 projects
participants · 6,651

Memory

70 projects
participants · 7,609

Observability

71 projects
participants · 5,463

Gateway

31 projects
participants · 2,637

Model Infra Landscape 2026

Model Infra

Serving

Post-Train

Deploy

 **Ollama**

 **NVIDIA Dynamo**

 **Xorbits Inference**



Rienforcement Learning

 **verl**

 **AReaL**

 **Slime**

Miles



Inference

 **LLM**

 **SGL**

 **LLaMA++**

 **OpenVINO**

 **Transformers**

 **TensorRT-LLM**



Supervised Fine-tuning

 **swift**
LLM training and deployment framework

 **unsloth**

 **LLaMA-Factory**
Easy and Efficient LLM Fine-Tuning

Pre-Train

Framework & Parallel

 **PyTorch**

 **Megatron-LM**

 **deepspeed**

 **Paddle**



Evaluation & Observability

 **mlflow**



Robotics Infra

 **LeRobot**



Compiler & Accelerator

 **Triton**

 **MLIR**

 **TransformerEngine**

 **CUTLASS**

FlashAttention

 **FlashInfer**

RAPIDS

 **DeepEP**

Data

Data Labeling

 **Label Studio**



Data Integration

 **Airflow**



Data Governance

 **Open Metadata**

 **DataHub**



 **Paimon**

 **Hudi**

 **DELTA LAKE**

 **APACHE GRAVITINO**

Compute & Scheduling

 **RAY**

 **Kubeflow**

 **VOLCANO**

 **Spark**

Model Infra: 规模化供应 Token 是重心

从 release、issue 与社区动作看：更快发版 · 更强 PD 分离 · 更重调度 · 更重稳定性。

01 Agent 改变 Token 的消费结构

SGLang issue [#21846](#) Roadmap

2026 年 4 月的 issue 提出 “Distributed KVCache System For Agentic Workload” roadmap，动机里明确写到 agentic workloads 正在带来 KV cache storage 与 transfer volumes 的快速增长，现有 PD 分离 + HiCache 已出现瓶颈。

02 从推理引擎到推理系统的构建

Dynamo issue [#5506](#) Roadmap

H1'26 roadmap: 重点领域不只包括性能，还明确包括 Production Grade Serving & Scaling、Router and KV Caching、Agents;

03 工业场景最痛的是稳定性


SGLang issue [#20252](#) Bug

真实大规模部署 qwen3-32b-fp8，配置为 90 个 prefill + 30 个 decode，H20。当部分 prefill 节点重启/迁移时，decode 不断重试，健康检查失败，router 移除 worker，流量压向剩余节点，随后在高 QPS 下出现 cascading failure 与 503。

Serving Infra OpenRank Top 5

Repo-level monthly OpenRank trend | 2025-05 to 2026-04

OpenRank



Source: 2605_agentic_projects.csv | activity proxy: OpenRank

vLLM

v0.21.0

2026-05-15

llama.cpp

b9279

2026-05-22

SGLang

v0.5.12

2026-05-16

TRT-LLM


v1.3.0rc15

2026-05-21

Large Models Landscape 2026

Model





 open source  closed source  #1 Highest ranking on OpenRouter LLM Leaderboard (Top 9 Weekly Usage & Trending*)



Model: 没有单一冠军



从关注谁是最强模型，到关注一个任务需要哪组模型。在质量约束下，按任务分配模型的有效性在学术和工业界正在被验证，模型路由的收益已经被量化。



谁在被下载和改造

谁在真实调用里吃到 token

论文给出 Cost vs Quality 对照

同一任务不必让最贵模型做完每一步。

RouteLLM

>2x

在部分 benchmark 上，路由可在不损失响应质量的条件降低成本超过 2 倍

IPR

43.9%

在一个大型云平台部署中，IPR 在与 Claude 家族最强模型质量持平情况下，实现 43.9% 成本下降

Sources: RouteLLM (CVPR 2025)· IPR (EMNLP Industry 2025)

Litellm 社区检索中的真实需求

"cost based routing"	23	10 issues / 13 PRs
"lowest cost"	18	6 issues / 12 PRs
"budget routing"	37	8 issues / 29 PRs
"spend tracking"	76	20 issues / 56 PRs

在 LiteLLM 社区里，routing / budget / spend governance 已经是高频工程议题。

Source: GitHub Search API · repo:BerriAI/litellm · 2026-05-22

三层架构互相咬合： 任务入口、生产底座和模型能力彼此塑形

Agent 要做更长任务，会逼 **Model Infra** 降低推理成本、提高上下文吞吐和可观测性；

Model Infra 变强，又让在某些任务上更有经济性的小模型、专用模型进入生产；

Model 层的推理、工具调用、多模态能力提升，也会让 **Agent** 不断越过聊天框边界。

03

趋势与项目故事

技术趋势的变化，还发生在项目如何描述自己

Coding Agents 的涌现： 从写代码工具，变成软件生产入口



作为 2026 年 Agentic AI 第一波真正规模化的场景，Coding Agents 的壁垒不只取决于模型能力，而是环境、工作流与 harness 的整合。

CLI-first	进入本地 repo、shell、测试和 git Claude Code · Codex · Gemini CLI · OpenCode · Qwen Code · Goose
IDE-first	保留编辑器心智，人类随时审查 Cursor · Cline · Kilo Code · Windsurf · Junie · Continue
Cowork / Cloud	从 issue 到 PR，后台执行任务 Copilot Agent · Devin · OpenHands · Paperclip · Multica
Harness	记忆、hooks、路由、成本和团队编排 claude-mem · beads · oh-my-* · cc-switch · vibe-kanban

78 相关项目

3.86M 累计 Star

14,019 4月参与者

竞争焦点

上下文资产 任务入口 团队化执行

项目正在重写自己的自我介绍

同一批项目开始把自己从 app、RAG、terminal、metadata，重新描述为 harness、context、runtime、operator。

96 / 226

项目 description 出现变化

agent		21
harness		6
context		5
workflow		4
mcp		3

agent / harness/ context / workflow

成为项目自我定位的新词汇

DeerFlowbytedance/deer-flow	
Deep Research framework before DeerFlow is a community-driven Deep Research framework, combining language models with tools like web search, crawling, and Python execution.	SuperAgent harness that researches, codes, and creates after An open-source long-horizon SuperAgent harness that researches, codes, and creates. With sandboxes, memories, tools, subagents and message gateway.
LobeHublobehub/lobehub	
AI chat framework before Lobe Chat - an open-source, modern-design AI chat framework. Supports Multi AI Providers, Knowledge Base (RAG), Multi-Modals.	Agent harness / Chief Agent Operator after LobeHub is your Chief Agent Operator, organizing your agents into 7x24 operations by hiring, scheduling, and reporting on your entire AI team.
MLflowmlflow/mlflow	
Machine learning lifecycle before Open source platform for the machine learning lifecycle.	AI engineering platform for agents after The open source AI engineering platform for agents, LLMs, and ML models. MLflow enables teams to debug, evaluate, monitor, and optimize production-quality AI applications.

典型定位迁移路径：从工具链到执行栈

Description 的变化把生态从“做一个 AI 应用”推向“让 Agent 进入真实任务系统”。

LLM App / Builder
DifyLangflowActivepieces
RAG / Vector / Data
RAGFlowDataHubmem0Chroma
Dev Env / Terminal
CoderWarpDaytonaOpenSandbox
LLMOps / MLOps
MLflowLangfusePromptfooOpik
RL / Inference
SGLangKServeAReALverl

Agentic Workflow
Context / Memory
Agent Runtime
AgentOps / AI Engineering
Agent / Workload Infra

RAGFlow	infiniflow/ragflow
before	open-source RAG engine based on deep document understanding
after	fuses RAG with Agent capabilities to create a superior context layer for LLMs
RAG Engine → Context Layer	
AReAL	inclusionAI/AReAL
before	Distributed RL System for LLM Reasoning.
after	The RL Bridge for LLM-based Agent Applications. Made Simple & Flexible.
RL Reasoning System → Agent Bridge	

项目说自己“不是什么”

当一个项目反复说 “Not a ...”，它往往不是在解释功能，而是在摆脱上一代生态标签。

RightNow-AI/openfang README.md

What is OpenFang?

- Not a chatbot framework.
- Not a Python wrapper around an LLM.
- Not a “multi-agent orchestrator.”
- Agent Operating System

paperclipai/paperclip README.md

What Paperclip is not

- Not a chatbot.
- Not an agent framework.
- Not a workflow builder.
- Not a prompt manager.
- Not a single-agent tool.

被否定的旧标签： chatbot framework / LLM wrapper / orchestrator / workflow builder / prompt manager

被强调的新标签： AgentOS、runtime、harness、context、 control plan

04

开发者与 AI 工具

AI 工具越强，人的责任越重

谁在参与 Agentic AI 生态?

56 万+参与者, 是工具作者、基础设施公司、全球节点和自动化账号共同生产的网络。

563,973 2026 YTD 参与者 · 226 个项目

1 贡献重心跨过应用层

Agent 项目显眼, 但基础设施同样在前列。执行交给硅基后, 软件世界需要更多“道路、港口、电网”式基础设施。

2 芯片、云、模型、基础设施公司同时在场

算力、推理、开发者平台、企业数据平台都在通过开源项目进入 Agentic 工具链和开发者 workflow。

3 全球跨时区的生产网络, 不是单一硅谷故事


模型发布在一个地方, 推理优化在另一个地方, coding agent 入口在第三个地方, 由不同国家的维护者一起把变更送进主干。

198 bot/app actors (2.0%) · 不只是 CI, 还包括 code review、coding connector、自动修复。

Top 贡献仓库所属组织 (Top 10K 中)



自报公司 (known n=2,920)



标准化国家 (known n=3,575)



Bot 不只是 CI: 它们开始读代码、审查 PR、参与协作



自动化能力正在沿软件生产链上移：从跑测试、发报告、更新依赖 → 读代码、提建议、生成补丁、参与 review。

类型	账号	OpenRank	重度使用的头部仓库	角色
CI / workflow	github-actions[bot]	3,505	anthropics/claude-code	测试、发布、自动化
Agent review	greptile-apps[bot]	1,125	openclaw/openclaw	代码理解和 PR review
Coding connector	codex-connector[bot]	782	openclaw/openclaw	coding agent 仓库入口
AI review	coderabbitai[bot]	432	NVIDIA/TensorRT-LLM	自动代码审查
Coding assistant	gemini-code-assist[bot]	418	vllm-project/vllm	工程协作助手
Dependency	dependabot[bot]	235	langgenius/dify	依赖和安全更新
Merge queue	pytorchmergebot	233	pytorch/pytorch	大型项目合并流程
Coverage	codecov[bot]	230	BerriAI/litellm	覆盖率反馈

Coding Agent: 硅基执行层




OpenRank Top 100 Agentic AI Projects · 2026-05



使用最多 Agent 的项目

1	google/adk-python	8
2	CherryHQ/cherry-studio	6
3	BerriAI/litellm	5
4	langgenius/dify	5

各 Coding Agent 采用率



检测方法: 通过 GitHub API 扫描仓库文件树, 识别 CLAUDE.md / .cursor / AGENTS.md / .codex / .windsurfrules / .gitignore 等标记文件

开发者：碳基定义层

Agentic AI 生态的开发者，是 builder、maintainer、researcher、startup founder 和大厂工程师共同组成的丰富画像。



steipete

独立工具作者

openclaw/openclaw

OR 1,454

Founder / PSPDFKit



teknium1

Agent 创业者

NousResearch/hermes

OR 341

NousResearch



Yeachan-Heo

Agent 工具开发者

oh-my-codex

OR 181

Silentist-Inc / Seoul



WillemJiang

大厂开源工程师

bytedance/deer-flow

OR 103

ByteDance



potiuk

基础设施维护者

apache/airflow

OR 47

Apache Airflow PMC



ashwin-ant

Coding Agent 构建者

anthropics/claude-code

OR 43

Anthropic



wenshao

中国开源基础设施

QwenLM/qwen-code

OR 43

Alibaba / fastjson



garrett4wade

研究者


inclusionAI/AReal

OR 42

Tsinghua University

开发者从执行者移动到定义者

AI 工具越强，人的责任越重。
开发者的价值从“亲自完成每个动作”，移动到“定义目标、约束行动、验证结果、承担责任”。



- 看似矛盾，其实合理：
- | | | |
|----------------------------------|---|-------------------------|
| 1 工具只能补全一行代码时 | → | 人只需判断这一行 |
| 2 工具能改几十个文件、跑测试、开 PR、回应 review 时 | → | 人要设计边界、写清验收标准、管理权限、检查结果 |
| 3 工具能自主规划、拆分任务、长期执行时 | → | 人要定义目标、设置护栏、审计过程、为结果负责 |

05

最后

软件会继续被重写，但开源仍然有不可替代的位置

软件还会被继续重写

Agent 会成为软件的用户。

Token 会成为软件的能源。

执行交给硅基，定义留给碳基。

开发者越来越变成定义目标、设计约束、验证结果、承担责任的人。

开源不会自动胜利，但开源仍然有不可替代的位置

Towards inclusive AGI，更像一个朴素的愿望：

AI 不是少数人的黑箱，

不是只属于大公司的产能机器，

而是可以被更多人理解、使用、改造和分享的公共技术。

Thanks!

 <https://opensource.antgroup.com/>

 @antgroup/agentica-landscape

 @inclusionAI

 @ant_oss



蚂蚁开源公众号

共同建设的 AGI

AI 不是少数人的黑箱，
而应该成为可以被更多人理解、使用、改造和分享的公共技术

Agentic AI 三层生态架构



从上层任务入口，到中层 token 供应链，再到底层模型能力；Agent 时代的软件栈正在重新分工。



Inclusion AI: Bringing AI Advances to Everyday Life



AI Service

General

Ling Guang

Omni-modal AI assistant

Financial



MA XIAO CAI

AI Financial Steward

Healthcare



AQ

A Health Steward You Can Trust

Life Services

Payment, Transport,
Home Assistant...

Agent Infra

Agent Harness



AWorld

Search, understand, reproduce,
and improve an idea with ease

Agentic Sandbox



AEnvironment

Standardized environment
infrastructure for Agentic AI
development

Agent Search



ASearcher

An Open-Source Large-Scale
Reinforcement Learning Project for
Search Agents

Model Infra

AI library



cuLA

High-performance
CUDA kernels for linear
attention variants

Humming

GEMM kernel library
specifically designed for
quantized inference

Pre Train



DLRover

An Automatic Distributed
Deep Learning System



ATorch

An industrial extension
library of PyTorch to
accelerate large scale
model training

Post Train



AReal

The RL Bridge for LLM-based
Agent Applications. Made
Simple & Flexible

ASystem

A Post-training Self-learning
Infrastructure

DLLM



dInfer

An Efficient Inference
Framework for Diffusion
Language Models

dFactory

Easy and Efficient dLLM
Fine-Tuning

Model

Language

Ling



Ant Ling Model

Multimodal

Ming

Reasoning

Ring

Efficiency

LLaDA

Open-sourced across all sizes, all modalities, and all
series, building a solid foundation for AGI

Spatial Intelligence

LingBot-Depth
LingBot-Map



Embodied Intelligence Model

Action

LingBot-VLA
LingBot-VA

Environment Reward

LingBot-World

Bridging intelligence from the
digital realm to the physical world

Inclusive AGI: 智能不应是少数人的特权

蚂蚁集团开放 AGI Initiative inclusiveAI 的三大主张：



Available 开放可及

模型和工具应尽可能开放，让开发者、研究者、行业专家和中小机构都能接触、看懂、调整。开放权重、数据工具、推理引擎与 Agent 协议，都是降低门槛的方式。智能要成为基础设施，必须能被更多人检查、适配和共同改进。



Affordable 可负担

AI 要真正走进垂类场景，医疗、金融、政务、教育、公益、乡村和中小企业，而不只是高端订阅。真正困难的不是让 AI 解漂亮的题，而是以足够低的成本帮助一个老人挂号、一个小商家经营、一个普通家庭处理生活服务。



Inclusive 包容参与

AI 价值不应只被 token 消费大户或少数平台拿走。开发者、开源维护者、数据贡献者、行业专家和普通用户都应在生态里有位置。要尊重真实流程和人的经验，让进步通过协作继续复利，而非单向发布。

Thanks!

 <https://www.inclusion-ai.org/>

 @inclusionAI

 @inclusionAI

 @TheInclusionAI



蚂蚁开源公众号