

Miles: 面向企业场景的强化学习框架

董仕

Member of Technical Staff, RadixArk

2026 年 5 月 23 日

为什么我们需要强化学习 (RL)?

RL 是**泛化程度最高**的提升模型推理能力和工具调用能力的训练方式



什么是 Miles?

Miles 是一个面向企业场景的 RL 框架, 专为**超大规模**后训练设计




Miles 概览

- "Every journey of a thousand miles begins with a single rollout."
- 面向大模型 post-training 的开源**企业级** RL 框架
- 高吞吐 rollout: SGLang
- 可扩展训练: 以 Megatron-LM 为训练引擎
- 精度 / 稳定性 / 可观测性: 工程能力对齐**万亿参数级别模型, 1k+ GPU 级别集群**
 - 与 Slime 共同演化: Slime 的可靠性已经在超大规模训练中获得验证 (GLM-5 series)
- Day-0 支持前沿模型: DeepSeek-V4, GLM-5, Qwen 3.6, ...

设计理念

- 极简核心, 多元扩展 (Small core, many edges)
 - Trainer 是一个短小的 Python 程序, 几乎所有行为都可以通过命令行参数自定义
- 匹配硬件 (Match the hardware)
 - NVLink / InfiniBand / RDMA 是万亿参数级别模型训练的真正瓶颈, 优先围绕互联做优化
- 系统优先 (Systems-first)
 - 将路由失配 / 精度漂移 / NCCL 挂死等会杀死大规模训练任务的稳定性问题置于**最高优先级**

Miles 总体架构



核心组件: 四个对象 + 一个循环

- 四个对象:
 - Prompt Dataset: JSONL on disk 或 `--data-source-path`
 - Rollout: SGLang 引擎 (router 负责协调多个 rollout engine)
 - Reward Model: 内置 `--rm-type`, 或自定义 `--custom-rm-path`
 - Actor: 加载 Megatron checkpoint; Reference 模型由 `--ref-load` 指定
- 一个训练循环 (sample $\rightarrow$ score $\rightarrow$ optimize $\rightarrow$ sync):
 - 采样: 从数据集中抽取一批 prompt, 由 SGLang 生成对应的 response
 - 评分与更新: 计算 reward, 对每个 batch 计算 GRPO loss 并反向传播
 - 权重同步: 通过 P2P 将更新后的 actor 权重推送到所有 rollout 引擎
- 同时支持 async training: sampling 与 weight update 完全独立运行

关键技术 I — R3: Rollout Routing Replay

- 问题: MoE router 对每个 token 选 top-k 专家
 - FP8 与非确定性 kernel 导致同样权重下, 推理与训练选中的 expert 不一致, 梯度被算到错误的 expert 上
 - 训练过程中累积放大, 导致策略最终发散
- 方案: 推理时记录路由信息, 训练时按位复放, 实现 bit-identical 专家分配
- 工程接入:
 - SGLang: 开启 `enable_return_routed_experts` 选项, 推理时返回每个 token 在每一层选中的专家
 - Miles: 通过 `--use-rollout-routing-replay` 启用, 训练时按位复放路由

关键技术 II — 统一低精度训练框架

- 一条量化路径覆盖 rollout 与 trainer, 端到端 FP8 sampling + training
 - Rollout 与 trainer 策略权重 bit-identical
- 已支持精度: BF16 / FP8 / MXFP8 / INT4-QAT (W4A16)
- 测试中: NVFP4 训练 recipe
- off-policy 修正调整:
 - Truncated Importance Sampling (TIS)
 - Masked Importance Sampling (MIS)
- 效果: 大规模低精度 RL 全程稳定收敛, 无需高精度兜底

关键技术 III — speculative rollout + 在线 MTP-SFT

- 动机: Rollout 占整体 wall-clock 一半以上, 加速 rollout 就是加速训练
- 难点: speculative decoding 依赖 draft / MTP 模型, 但 actor 在持续更新
 - 训练几百步后, draft 与 actor 分布漂移, acceptance rate 跌穿地板
- Miles 的方案: 在线对 MTP 层做 SFT, 持续与 actor 对齐
 - Acceptance rate 全程保持在高位
 - speculative decoding 的 rollout 加速比可以保持稳定

原生 Agentic Rollout

- 面向 Agentic 任务的原生支持:
 - 工具调用 (tool use)
 - 多轮对话 (multi-turn dialogue)
 - 浏览器搜索 (search)
 - 代码执行 (code execution)
- 全部通过简洁的 Python 扩展点接入, 不用 fork trainer
- 同一套 chat template 与 reward 接口贯穿 SFT 与 RL
- 面向企业场景: 真实场景里很少是 single-turn QA, Agentic 训练是默认配置

极简核心, 众多扩展点

- Trainer 是一个短小的 Python 程序, 几乎每个行为都可被替换
- 20+ 扩展点 (通过命令行参数接入, 无需修改框架代码):
 - rollout / reward / loss / filter / Megatron hook / chat-template / data-source ...
- LoRA 训练与推理
 - SFT 与 RL recipe 均支持 LoRA
 - Adapter 无缝加载入 SGLang, 不再需要 merge / convert 步骤
- 企业团队可以在 fork-free 的前提下持续改进自己的模型训练流水线

容错与长跑能力

- 面向**数周大规模训练 + 数百节点**的真实生产任务设计
- Rank 级故障恢复 (rank-level recovery)
 - 单 rank 挂掉不必全任务回滚
- Step 级训练回放 (step-level replay)
 - 异常后从最近 step 重放, 不丢已 commit 的训练进度
- RDMA P2P 权重同步
 - 万亿参数 actor -> rollout 权重 sync 不再是 wall-clock 瓶颈
- 可观测性: Wandb / Chrome trace / Grafana dashboard (后续路线)

硬件与模型支持

- 硬件支持:

- NVIDIA: GB300, GB200, B200, B100, H200, H100, A100
- AMD: MI300X, MI325, MI350, MI355X (via ROCm)

- 模型 Day-0 上线:

- DeepSeek-V4 Pro / V4 Flash, V3, R1
- GLM-5.1, GLM-5, GLM-4.7-Flash, GLM-4.5
- Qwen 3.6 MoE, Qwen 3.6, Qwen 3.5, Qwen 3-Next-80B-A3B-Thinking
- Kimi-K2.6 / K2.5 / K2-Instruct / Thinking, Moonlight-16B-A3B
- Nemotron-3-Super, Nemotron-3-Nano (MoE)

路线图: What's Next

- 完成 NVFP4 训练 recipe 测试, 与 FP8 / MXFP8 拉齐
- FSDP-only trainer 路径
 - 面向没有 Megatron 经验的团队, 降低上手门槛
- 内置 profiling 与可观测性
 - Chrome-trace 分析, Grafana dashboard
- 原生 on-policy distillation 支持
 - OPD 已经成为标准训练范式之一
- 新硬件支持: Nvidia Rubin series
- Diffusion & Omni 模型训练支持

GitHub: github.com/radixark/miles

Docs: radixark.ai/miles/docs

