




蚂蚁开源技术沙龙

Agent 记忆测评之痛：OpenLoomi 记忆成长心得

朵晓东 Ethan Duo

MelandLabs 创始人，OpenLoomi 创始人

前蚂蚁集团资深技术专家



朵晓东

MelandLabs 创始人,
OpenLoomi 创始人,
前蚂蚁集团资深技术专家,
多个开源项目发起人,
连续创业者



蚂蚁开源
ANT OPEN SOURCE



章节目录

1. 背景介绍

2. 问题思路

3. 测评体系

4. 展望



背景介绍



OpenLoomi

OPEN SOURCE HARNESS

OpenLoomi（开源 Harness 引擎）

开源 Harness 框架，主打全域上下文图谱、自进化记忆和隐私安全等特性，支持开发者构建开源的主动式 AI 工作伙伴。

<https://github.com/melandlabs/openloomi>



COMMERCIAL AI PRODUCT

Alloomi（领域商业化产品）

基于 OpenLoomi 内核打造，服务专业 C 端与 AI 原生团队智能协作与生产力助手，面向 SMB、创始人、销售、法务等领域垂类场景和人群。

章节目录

1. 背景介绍
- 2. 问题思路**
3. 测评体系
4. 展望



构建基于全域上下文图谱的确定性执行闭环

人: 情商 & 推理

- 基于记忆 & 理解上下文推理
- 归因分析与主动人机互动
- 个性化判断

人: 记忆 & 理解

- 可扩展来源: IM, 邮件, 文件, 截屏, 录音...
- Know-how 理解: 决策链路、工作流
- 事实理解: 人际关系 $\neq$ 半/项目 > 角色 $\rightarrow$ 图谱、跨会话事实、知识库、用户偏好
- 记忆能力: 长周期、主动性、动态自进化

人感知环境: Interface

Chat, Artifacts
Mini/Gen App
Messaging App, CLI
时序触发

环境: 工具 & Harness

- 工具、Bash、文件系统、Connectors
- Sandbox、Browser、Compute
- 信任边界
- 模型 = Engine, Harness = Car

环境: 治理 & 审计

- 审计、可观测
 - 用量、偏好
 - 安全、权限
- (在线)准确性测评



LLM Infra

数据源


LLM

为什么 Agent 记忆和持续学习是难题



Memory Brittleness

Agent 需要在海量、零散的数据中建立逻辑关联，只是冰冷的文字压缩，无法支撑有效的决策和经验沉淀




Temporal Reasoning

时间 & 轨迹等上下文在真实的业务场景中持续缺失，如“上周、上月至今”的范围类问题回答效果差，缺乏动态更新、跟踪的长程知识存储



Forget Nothing ≠ Remember What Matters

现有方案往往在信息过载或推理断层中陷入困境，难以适应复杂的动态任务场景，频繁陷入上下文腐烂，压缩即失忆等问题




Evaluation Dilemma

测评体系缺口巨大，大量场景记忆效果依赖人工主观体验判断，领域 Benchmark 标准缺乏且缺少持续维护更新，无法持续根据业务发展量化改进

Memory Brittleness: 上下文图谱 & 结构化记忆洞察


由 Coding Agent 数据闭环流程启发



✓ 上下文图谱全集 (时间 + 空间维度)

全局/局部偏好 + 结构化代码 + GitHub Issue/Kanban + Git History + 某些 Coding Agent 支持代码模式自动学习

OpenLoomi 个人上下文图谱构建闭环流程



✓ 上下文图谱全集 (时间 + 空间维度)

全局/局部偏好 + 不可变原始上下文 + Insights 结构记忆洞察 + Timeline + 全局关系图谱 + 自进化记忆

<https://github.com/melandlabs/openloomi/blob/main/skills/openloomi-connectors/SKILL.md>


<https://github.com/melandlabs/openloomi/blob/main/skills/openloomi-memory/SKILL.md>

Memory Brittleness: 记忆图谱连接（空间维度）



基于**赫布 Hebbian 学习法则**的核心逻辑，基于 agentic 动态强化机制，自适应模仿人类大脑联想思维，快速召回关联记忆

 关联召回，强度增加（语义检索 / 关键词检索 / ...）



长时间未访问 强度渐弱



$$W_{new} = W_{old} + \alpha * (W_{max} - W_{old}) * activity$$
$$W_{decay} = w * e^{(-yt)}$$



用户访问 Insight A



POST /api/insights/[A]/view



recordInsightView()



查询近期其他相同关键词或相近语义的访问记录 (insightViewHistory)



对每个近期 Insight B



strengthenConnection(A, B)

 连接已存在?



YES: applyPotentiation()
strength *= 1.2, stability *= 1.1



NO: 插入新连接
strength = 0.1, stability = 1.0

Temporal Reasoning: 时间旅行查询 (时间维度)



打破静态记忆的时间壁垒

为 Agent 运行时提供“时间旅行”API，可跨越时间维度回溯版本化历史状态，tracing 记忆内容演化过程。



```
## Temporal Queries (Time-Travel)

Temporal validity enables "time-travel" queries - seeing what insights were relevant at a specific point in time.

### Commands

```bash
Get insights valid at a specific point in time
node $SKILL_DIR/scripts/openloomi-memory.cjs get-insights-as-of 2024-01-01

Get currently valid insights
node $SKILL_DIR/scripts/openloomi-memory.cjs get-current-insights

Get insights overlapping a time interval
node $SKILL_DIR/scripts/openloomi-memory.cjs get-insights-in-interval 2024-01-01 2026-06-01
```
```



时间旅行查询

“上周我做了什么？”
“给我写一份周报”




返回上下文快照



连接器 / 集成 / 屏幕
/ 声卡 / Mic /... 等
实时数据

Forget Nothing $\neq$ Remember What Matters: 遗忘引擎



Phase 1: Short + Mid

- 扫描 L1 记忆记录
- 评分 < 0.65则升层
- 按天/窗口分组 – 生成 L1 Summary



Phase 2: Mid + Long

- 扫描 L2 记忆记录
- 评分 < 0.45则升层
- 按天/窗口分组 – 生成 L2/L3 Summary

章节目录

1. 背景介绍
2. 问题思路
- 3. 测评体系**
4. 展望



测评体系概述



01. 准确性 Accuracy

衡量生成答案与客观事实的匹配程度，采用 F1-Score、BLEU 等专业指标量化评估，确保可靠性与精准度。



02. 召回率 Recall Rate

评估系统在面对复杂查询时，从历史记忆库中正确检索并关联相关信息的比例



03. 时序推理 Temporal Reasoning

测试系统处理时间敏感型查询、理解事件先后顺序与时效性约束的能力



04. 知识更新 Knowledge Update

考察记忆系统在知识迭代、事实变更时的动态适应能力

LoCoMo 对话记忆评估

Stony Brook University · 学术基准数据集

LoCoMo (Long-term Conversation Memory) 包含真实对话记录及其对应的观察、摘要和 QA 对，专门用于评估记忆系统在不同检索模式下的表现。



dialog

原始对话历史



observation

带引用的摘要观察



session_summary

会话级摘要

Question Categories

1

single_hop

单记忆检索事实召回

2

temporal

日期/时间推理问题

3

multi_hop

跨会话多步推理

4

open_domain

开放域融合问答

| 会话 | 通过 | 总数 | 通过率 |
|----------------|------------|------------|---------------|
| conv-26 | 150 | 154 | 97.40% |
| conv-30 | 80 | 81 | 98.77% |
| conv-41 | 152 | 152 | 100% |
| conv-42 | 191 | 199 | 95.98% |
| conv-43 | 167 | 178 | 93.82% |
| conv-44 | 113 | 123 | 91.87% |
| conv-47 | 145 | 150 | 96.67% |
| conv-48 | 187 | 191 | 97.91% |
| conv-49 | 146 | 156 | 93.59% |
| conv-50 | 154 | 158 | 97.47% |

96.3%

端到端准确率



性能对标 SOTA：与 agentmemory、mempalace 等当前主流开源记忆项目基本持平，达到行业领先的记忆还原与理解水平。

LongMemEval-S

500

QA Pairs

6

问题类型

10+

会话 Session

Multi

评估模式

从真实对话中提取包含短期记忆、跨会话推理、时间推理等多种类型的问题，用于评估 Agent 在复杂场景下的记忆召回能力。



真实场景记忆评估基准

从真实多轮对话语料中提炼，涵盖短期即时记忆、多线索复合推理、时间线顺序推理三大核心维度

97.6% 端到端准确率

在复杂的多模态记忆推理任务中，系统展现出较高的鲁棒性与准确性。

| Type | Count | Accuracy |
|---------------------------|-------|-----------------|
| single-session-assistant | 56 | 100% (56/56) |
| single-session-user | 70 | 100% (70/70) |
| multi-session | 133 | 98.5% (131/133) |
| temporal-reasoning | 133 | 97.7% (130/133) |
| knowledge-update | 78 | 94.9% (74/78) |
| single-session-preference | 30 | 90.0% (27/30) |
| Overall | 500 | 97.6% (488/500) |



性能对标 SOTA：与 agentmemory、mempalace 等当前开源社区最优秀的记忆系统项目基本持平

Conext Learning

| RANK | MODEL | ORGANIZATION | SOLVING RATE (4STD) |
|------|------------------------|--------------|-------------------------------|
| 1 | GPT 5.5 (High) | OpenAI | 22.2% <div><div></div></div> |
| 2 | GPT 5.4 (xHigh)† | OpenAI | 21.7%† <div><div></div></div> |
| 3 | GPT 5.4 (High) | OpenAI | 19.3% <div><div></div></div> |
| 4 | GPT 5.1 (High)† | OpenAI | 17.3%† <div><div></div></div> |
| 5 | Claude Opus 4.6 (High) | Anthropic | 17.0% <div><div></div></div> |
| 6 | Gemini 3.1 Pro (High) | Google | 16.9% <div><div></div></div> |
| 7 | Gemini 3.1 Pro† | Google | 16.0%† <div><div></div></div> |
| 8 | Hy3 preview (High) | Tencent | 15.7% <div><div></div></div> |
| 9 | Seed 2.0 Pro (High) | ByteDance | 15.5% <div><div></div></div> |

| Type | Count | Accuracy |
|----------------------------|-------|-----------------|
| Domain Knowledge Reasoning | 55 | 41.8% (23/55) |
| Language Understanding | 120 | 38.3% (46/120) |
| Information Extraction | 165 | 27.9% (46/165) |
| Text Generation | 160 | 37.5% (60/160) |
| Overall | 500 | 35.0% (175/500) |



单独 SOTA 模型仅取得 **~22%** 的解决率，结合 Aloomi Harness 大约提升至**35%**

证明在基模能力不变的情况下，Harness Engineering 可以有效提升生活、工作场景的问题解决率

当下测评体系的问题

01

数据分布失真

真实场景数据稀疏，多模态数据零散且噪声大，整体偏静态化，作为标准的 Ground Truth 本身也存在标注错误的情况。



02

核心数据缺失

忽略了真实场景的重要数据如关联网络，缺乏对事件发展脉络的持续跟踪与分析，难以评估记忆的逻辑性与连贯性。



03

评估效应失真

由于模型推理能力的快速迭代，过往 Benchmark 的达成门槛及验证效果大幅下降，基本失效，测评通过但在真实业务中表现差。



04

亟需新基准体系

类比软件工程领域的 SWE-Bench 和不断提升真实感和难度的 Program Bench，真实业务场景缺乏标准测评。



Spark — 阶段 1



目标

面向工作场景的全域上下文图谱，全面测评人、事、项目、决策、工作流及其完整演进脉络



核心差异

聚焦时空与全域关系图谱 Rubrics
复合化测评：评估复合提问的整体正确性，避免单点正确

典型场景和 Rubrics 示例



01. 关系图谱构建

如：精准识别工作中成员的角色定位、合作关系及跨部门协作链路，还原真实人际网络互动。



02. 项目风险与问题预警

如：从项目执行上下文中挖掘潜在风险，预判关键节点延期可能性及资源匹配失衡等重要问题，提供前置警示依据。



03. 历史经验沉淀与复用

如：系统性提取项目成功路径与失败教训，归纳可迁移的方法论，形成标准化、可复用的组织级知识库资产。



经验总结

LESSON

01

记忆不是越久越好

LESSON

02

遗忘算法比存储算法更难做好

LESSON

03

评分权重需要自进化调优

LESSON

04

测评体系是迭代改进的基础

LESSON

05

上下文准确性需要考虑时空维度

章节目录

1. 背景介绍
2. 问题思路
3. 测评体系
- 4. 展望**



展望

01



全域上下文图谱

Benchmark – Spark

全面理解测评人、事、项目、
决策、工作流及其完整演进脉
络

02



记忆模型

彻底解决当前 AI 互动中信息
遗忘、上下文脱节、每次都从
零开始的顽疾

03



自学习模型

复用图谱沉淀的全链路工作
信息动态优化能力，贴合场景
持续迭代升级

欢迎关注



项目官网:

<https://openloomi.ai/>



GitHub:

<https://github.com/melandlabs/openloomi>



欢迎

Star, Fork, PR

— 微信公众号 —

